卒中后癫痫五套算法架构

第五次大跑数 · 全量结果汇编

A / B / C：21,459 例公共队列（Dryad v8）

D / E：温州 167 例真实队列

三合医研发团队 · 河南大学

2026-11-07

全部数字直接读取 results/ 原始 JSON 与 CSV，未做人工转录或修饰

每个表、每张图均注明源文件，可逐位核对

目　录

0　阅读指南：这本书是什么、怎么核对

1　数据与设计：队列、特征集、模型、跑数清单

2　A / B / C 全训练规模明细（144 次拟合）

3　主结果：n = 8,000 与全训练集锚点

4　校准与决策曲线

5　增量与配对比较：哪个特征块、哪个模型真正有用

6　特征重要性：A / B / C 的前十变量

7　特征集 A 的五折交叉验证与 OOF

8　D 研究：温州 167 例的首次发作时点预测

9　E 研究：抗癫痫药物与晚期 PSE 风险

10　图表总索引

11　复现锚点：文件指纹、关键数字、运行步骤

0　阅读指南

这份汇编是五套算法架构的账本。算法架构正文回答“这些数字说明什么”，本书回答四个更基础的问题：每个数字具体是多少；它在哪一种数据划分、哪一档训练规模、哪一个模型下得到；换一种划分是否还成立；以及这个数字可以在哪个原始文件里逐位核对。

本书覆盖第五次大跑数的全部最终结果：公共队列 A/B/C 三项研究共 **144 次模型拟合**；温州 167 例队列 D 研究 **300 次交叉验证拟合**；E 研究 **5 类效应估计、2,000 次 bootstrap** 与全部生存分析。所有数字由脚本直接写入 JSON/CSV，本书再由脚本读取生成，中间没有人工转录。

一条阅读建议：先看第 3 节主结果表（n = 8,000），再看第 5 节增量表；这两张表足以回答“哪个模型更好、哪个特征块有用”。第 2 节的全量明细用于核对与复现，不必顺序阅读。

0.1　数据流（一页看懂）

· 公共队列 21,459 例（事件 936，4.36%）→ 分层 80/20 划分（种子 42）→ 训练 17,167 / 测试 4,292（事件 187）。

· 去重臂：删除 7,815 条所有字段完全相同的重复行 → 13,644 例（事件 892，6.54%）→ 训练 10,915 / 测试 2,729（事件 178）。

· 特征集：A = 36 个入院特征；B = 70 个（A + 34 项实验室指标）；C = 74 个（B + 4 项卒中后并发症）。

· 模型：L2 logistic 回归（LR）、LightGBM（LGBM）、TabPFN v2（预训练检查点，零调参）。

· 训练规模：100、250、500、1,000、2,000、4,000、8,000、16,000、17,167；去重臂最后一档为 10,915；TabPFN 受上下文上限约束，最大 8,000。

· 温州队列 167 例（PSE 49 例，29.3%）→ D：核心 8 特征 / 扩展 24 特征，5 折 × 10 重复；E：ASM 暴露（134 vs 33）的观察性比较。

0.2　记号与缩写

表 0-1　本书反复出现的术语

术语	含义
AUROC	受试者工作特征曲线下面积；0.5 = 随机猜测，1 = 完美排序
AUPRC	精确率–召回率曲线下面积（average precision）；事件稀少时比 AUROC 更能区分模型
Brier 分数	预测概率与真实结局（0/1）的均方误差；越低越好，同时惩罚判别力与校准
校准斜率	把预测 logit 对真实结局做 logistic 回归的斜率；1 = 校准良好，< 1 = 概率被压缩/过度自信
校准截距	同一回归的截距；0 = 无系统性高估或低估
ΔAUROC	同一批测试患者上两个模型的 AUROC 之差；配对 bootstrap 2,000 次给出 95% 区间
n_train	训练子集例数（每一档都从训练集重新抽样，测试集始终不变）
full / dedup	原始全队列 / 去除完全重复行后的去重队列
LR / LGBM / TabPFN	logistic 回归 / LightGBM / TabPFN v2 表格基础模型
E 值	未测量混杂需要达到多强的关联，才能把观察到的效应完全解释掉
SMD	标准化均值差；绝对值 < 0.1 通常视为两组平衡
IPTW / AIPW	逆概率加权 / 增广逆概率加权，两类倾向评分方法
RMST	限制平均生存时间：在固定时间窗（此处 730 天）内的平均无事件时间

源文件：术语定义对应 docs/配置要求与复现说明.md 与各算法架构方法节。

0.3　怎么核对

· 每个表下都有“源文件”脚注；打开 results/ 下对应文件即可逐位核对。

· 重跑后，用第 11 节的锚点表比对到小数点后四位；任何一位不同都说明环境或数据版本不一致。

· 图中曲线由 preds_*.csv 的行级预测重绘；若图与表不一致，以表为准，并检查 preds 文件是否为 final 版本。

· 本书的“第五次”沿用项目内部计数；不同次跑数的口径可能不同，跨版本比较请只使用本书数字。

1 数据与设计

1.1 队列与划分

公共队列来自 Dryad 公开的缺血性卒中数据集（第 8 版），共 21,459 例，一年内继发性癫痫 936 例（4.36%）。固定分层 80/20 划分（种子 42）产生 17,167 例训练集与 4,292 例测试集；测试集含 187 个事件。去重臂删除 7,815 条所有字段完全相同的重复记录，剩 13,644 例（事件 892，6.54%），训练 10,915 / 测试 2,729（事件 178）。

一个值得注意的事实：被删除的 7,815 行里只有 44 个事件（0.56%），远低于全队列的 4.36%——重复记录以阴性随访为主。这正是去重臂要检验的：如果结论依赖这些重复的阴性记录，去重后应当改变。第 2–5 节会看到，结论没有改变，数值只发生了小幅移动。

表 1-1　两套数据划分

队列	总例数	事件数	事件率	训练例数	测试例数	测试事件
full（原始）	21,459	936	4.36%	17,167	4,292	187
dedup（去重）	13,644	892	6.54%	10,915	2,729	178

源文件：results/metrics_{full,dedup}_{A,B,C}_final.csv 的 n_train 网格；事件率 = 事件数 / 总例数。

1.2 三套特征集

A/B/C 共用同一套划分、同一批测试患者与同一组模型，唯一变化是特征块。这是本系列能够做“同一患者上的配对增量比较”的原因：A→B 的差值就是实验室块的贡献，B→C 的差值就是并发症块的贡献。

表 1-2　三套特征集的构成

特征集	变量数	构成	回答的问题
A	36	人口学（年龄、性别）、血管危险因素与病史、卒中病灶部位（脑叶/基底节/脑干/小脑等）、供血区与颈动脉斑块、大血管病变	仅凭入院即可得的信息能预测到什么程度
B	70	A 的 36 个 + 34 项实验室指标（血常规、凝血、生化、心肌酶、电解质等）	实验室块带来多少增量
C	74	B 的 70 个 + 4 项卒中后并发症（深静脉血栓、脑疝、脑积水、低蛋白血症）	后验变量还能不能带来增量（边界测试）

源文件：server/tabpfn_bench.py 的 FEATURES_A/B/C 定义；D 研究另有核心 8 特征与扩展 24 特征，见 8.1 节。

1.3 三个模型

三个模型代表三种归纳偏置：线性加性（LR）、树集成（LGBM）、预训练 Transformer（TabPFN）。三者使用完全相同的输入列与训练行，不做任何按模型的额外特征工程。

表 1-3　A / B / C 的模型配置

模型	实现	关键设置	说明
LR	scikit-learn LogisticRegression	C = 1.0；max_iter = 3,000；random_state = 42	实验室值按训练集 1/99 百分位缩尾；13 个偏态实验室变量 log1p；连续与有序变量标准化；二值变量原值。所有变换参数只来自训练行。
LGBM	LightGBM LGBMClassifier	n_estimators = 300；learning_rate = 0.05；num_leaves = 31；min_child_samples = 50；subsample = 0.8；colsample_bytree = 0.8；reg_alpha = 0.1；reg_lambda = 0.1；scale_pos_weight = 阴性/阳性	沿用源研究超参数，未在本数据上调参；随机种子 42。
TabPFN	TabPFN v2（预训练检查点）	n_estimators = "auto"；ignore_pretraining_limits = True；device = cpu；random_state = 42	零调参；仅在 n ≤ 8,000 时运行。检查点 SHA-256 见 11.1。

源文件：server/tabpfn_bench.py 第 130–165 行；预处理函数 lr_transform()。

D 研究使用不同配置：LR 的 max_iter = 5,000；LGBM 改为浅树（n_estimators = 100、num_leaves = 3、min_child_samples = 10），因为 n = 167 时深树会直接过拟合；TabPFN 配置不变。E 不是机器学习研究，而是观察性效应估计，方法见第 9 节。

1.4 跑数清单

下表是本次归档包含的全部拟合次数。A/B/C 的每一次拟合都产生一行指标（结果 CSV 共 144 行）；D 的 300 次拟合汇总为均值±标准差；E 的每次 bootstrap 重抽样都记录估计值，用于构造区间。

表 1-4　本次跑数的拟合次数

研究	数据	模型 × 规模	拟合次数
A/B/C full	17,167 训练 / 4,292 测试	LR 9 档 + LGBM 9 档 + TabPFN 7 档 = 25 / 特征集	75
A/B/C dedup	10,915 训练 / 2,729 测试	LR 8 档 + LGBM 8 档 + TabPFN 7 档 = 23 / 特征集	69
D	167 例，5 折 × 10 重复	3 模型 × 2 特征集 × 50 折次	300
E	167 例	5 类效应估计 + 2,000 次 bootstrap + 生存分析	—

合计 A/B/C 拟合 144 次。TabPFN 的 7 档为 100–8,000；16,000 与 17,167（或 10,915）档不运行。

1.5　统计协议

判别力用 AUROC 与 AUPRC；概率质量用 Brier 分数；校准用“预测 logit 对真实结局”的 logistic 回归（C = 1e6，固定）给出斜率与截距。所有区间来自测试行上的 **2,000 次配对 bootstrap**（种子 42，百分位法）；配对意味着每次重抽样都同时抽取两个模型的同一批患者，因此区间反映的是“同一批人上的差”，而不是两个独立样本的比较。决策曲线在 0.05–0.60 的阈值网格上以 0.01 为步长计算净获益。D 研究另用 5 折 × 10 重复的分层交叉验证、Kaplan–Meier 三分位与 log-rank 检验；E 研究用 bootstrap 区间、E 值与 90 天界标分析。

2　A / B / C 全训练规模明细

本节把 144 次拟合的每一条结果原样列出。每一行是一个训练规模；三组列分别是三个模型；每组内是 AUROC、AUPRC 与 Brier。“—”表示该模型在该规模没有运行（TabPFN 的预训练上下文上限为 8,000）。表格只做四位小数取舍，没有其他加工。

读表时注意三件事：第一，测试集始终固定，因此同一列内不同 n 的差异只来自训练集大小；第二，AUPRC 的随机基线约等于事件率（full 4.36%，dedup 6.52%），不是 0.5；第三，Brier 同时受判别力与校准影响，不能单独当作“准确率”。

2.1　特征集 A（36 个入院特征）

这是信息最少的一套特征：只有入院当时可得的人口学、病史、病灶与血管信息。

表 2-1　特征集 A，全队列：全部训练规模的指标（n = 100–17,167）

	Logistic regression			LightGBM			TabPFN v2		
n_train	AUROC	AUPRC	Brier	AUROC	AUPRC	Brier	AUROC	AUPRC	Brier
100	0.6251	0.0782	0.0418	0.5000	0.0436	0.0417	0.8184	0.1832	0.0390
250	0.8036	0.2011	0.0389	0.8491	0.2439	0.0586	0.8897	0.2818	0.0358
500	0.8163	0.1891	0.0403	0.8735	0.3403	0.0521	0.9098	0.3621	0.0332
1,000	0.7948	0.1647	0.0409	0.8778	0.2872	0.0515	0.9203	0.3740	0.0322
2,000	0.8185	0.1770	0.0406	0.9053	0.3679	0.0455	0.9314	0.4572	0.0305
4,000	0.8279	0.1899	0.0401	0.9275	0.4670	0.0412	0.9424	0.5675	0.0270
8,000	0.8553	0.2171	0.0396	0.9378	0.5785	0.0450	0.9445	0.6293	0.0248
16,000	0.8608	0.2260	0.0395	0.9464	0.6245	0.0547	—	—	—
17,167	0.8618	0.2271	0.0396	0.9460	0.6110	0.0567	—	—	—

源文件：results/metrics_full_A_final.csv。n 为训练例数；测试集固定为 4,292 例/187 事件（full）或 2,729 例/178 事件（dedup）。

表 2-2　特征集 A，去重队列：全部训练规模的指标（n = 100–10,915）

	Logistic regression			LightGBM			TabPFN v2		
n_train	AUROC	AUPRC	Brier	AUROC	AUPRC	Brier	AUROC	AUPRC	Brier
100	0.7791	0.1870	0.0594	0.5000	0.0652	0.0610	0.8193	0.2586	0.0545
250	0.8263	0.2942	0.0539	0.8231	0.2708	0.1056	0.8854	0.3772	0.0494
500	0.8484	0.2989	0.0534	0.8498	0.3513	0.0802	0.8959	0.4180	0.0470
1,000	0.8446	0.3095	0.0529	0.8899	0.4491	0.0634	0.9050	0.4794	0.0447
2,000	0.8400	0.3221	0.0524	0.8977	0.5303	0.0591	0.9185	0.5342	0.0423
4,000	0.8651	0.3261	0.0522	0.9151	0.5482	0.0588	0.9275	0.5700	0.0403
8,000	0.8724	0.3208	0.0527	0.9282	0.5935	0.0674	0.9309	0.5955	0.0391
10,915	0.8731	0.3235	0.0526	0.9328	0.6053	0.0713	—	—	—

源文件：results/metrics_dedup_A_final.csv。n 为训练例数；测试集固定为 4,292 例/187 事件（full）或 2,729 例/178 事件（dedup）。

全队列：LR 从 n = 100 的 0.6251 升到 n = 17,167 的 0.8618；LGBM 从 0.5000 升到 0.9460；TabPFN 在 n = 100 已达 0.8184，n = 8,000 为 0.9445。全表最高值出现在 LGBM、n = 16,000（0.9464）。去重队列（n = 100–10,915）的形态相同：LR 0.7791 → 0.8731；LGBM 0.5000 → 0.9328；TabPFN 0.8193 → 0.9309。

2.2　特征集 B（70 个：A + 34 项实验室）

实验室块把信息量推高一档；这也是本系列的主推配置。

表 2-3　特征集 B，全队列：全部训练规模的指标（n = 100–17,167）

	Logistic regression			LightGBM			TabPFN v2		
n_train	AUROC	AUPRC	Brier	AUROC	AUPRC	Brier	AUROC	AUPRC	Brier
100	0.8764	0.2778	0.0367	0.5639	0.0512	0.0420	0.9423	0.5431	0.0284
250	0.9394	0.5923	0.0241	0.9184	0.6849	0.0215	0.9885	0.9007	0.0112
500	0.9446	0.5989	0.0243	0.9702	0.8071	0.0180	0.9911	0.9120	0.0105
1,000	0.9414	0.6427	0.0222	0.9749	0.8605	0.0147	0.9941	0.9353	0.0085
2,000	0.9446	0.6826	0.0204	0.9837	0.8939	0.0122	0.9966	0.9580	0.0066
4,000	0.9560	0.7457	0.0193	0.9881	0.9275	0.0082	0.9962	0.9671	0.0047
8,000	0.9625	0.7753	0.0173	0.9923	0.9603	0.0050	0.9980	0.9821	0.0037
16,000	0.9647	0.7877	0.0167	0.9949	0.9685	0.0038	—	—	—
17,167	0.9648	0.7872	0.0167	0.9956	0.9705	0.0038	—	—	—

源文件：results/metrics_full_B_final.csv。n 为训练例数；测试集固定为 4,292 例/187 事件（full）或 2,729 例/178 事件（dedup）。

表 2-4　特征集 B，去重队列：全部训练规模的指标（n = 100–10,915）

	Logistic regression			LightGBM			TabPFN v2		
n_train	AUROC	AUPRC	Brier	AUROC	AUPRC	Brier	AUROC	AUPRC	Brier
100	0.8131	0.4012	0.0477	0.6626	0.0974	0.0631	0.8985	0.6301	0.0391
250	0.8967	0.5474	0.0402	0.8712	0.5933	0.0473	0.9674	0.8318	0.0224
500	0.9348	0.6778	0.0335	0.9471	0.7861	0.0274	0.9821	0.8866	0.0190
1,000	0.9500	0.7357	0.0298	0.9803	0.8743	0.0203	0.9915	0.9337	0.0131

	Logistic regression			LightGBM			TabPFN v2		
n_train	AUROC	AUPRC	Brier	AUROC	AUPRC	Brier	AUROC	AUPRC	Brier
2,000	0.9552	0.7604	0.0286	0.9838	0.9059	0.0180	0.9965	0.9680	0.0093
4,000	0.9621	0.7843	0.0270	0.9919	0.9481	0.0125	0.9981	0.9818	0.0066
8,000	0.9660	0.7944	0.0261	0.9964	0.9736	0.0078	0.9985	0.9861	0.0050
10,915	0.9663	0.7994	0.0254	0.9963	0.9764	0.0066	—	—	—

源文件：results/metrics_dedup_B_final.csv。n 为训练例数；测试集固定为 4,292 例/187 事件（full）或 2,729 例/178 事件（dedup）。

全队列：LR 从 n = 100 的 0.8764 升到 n = 17,167 的 0.9648；LGBM 从 0.5639 升到 0.9956；TabPFN 在 n = 100 已达 0.9423，n = 8,000 为 0.9980。全表最高值出现在 TabPFN、n = 8,000（0.9980）。去重队列（n = 100–10,915）的形态相同：LR 0.8131 → 0.9663；LGBM 0.6626 → 0.9963；TabPFN 0.8985 → 0.9985。

2.3 特征集 C（74 个：B + 4 项并发症）

并发症块位于预测时点之后，本应不带来增量；这张表是验证。

表 2-5 特征集 C，全队列：全部训练规模的指标（n = 100–17,167）

	Logistic regression			LightGBM			TabPFN v2		
n_train	AUROC	AUPRC	Brier	AUROC	AUPRC	Brier	AUROC	AUPRC	Brier
100	0.8779	0.2733	0.0368	0.5639	0.0512	0.0420	0.9440	0.5630	0.0276
250	0.9400	0.5958	0.0240	0.9184	0.6849	0.0215	0.9886	0.8965	0.0114
500	0.9452	0.6049	0.0242	0.9673	0.8124	0.0178	0.9907	0.9130	0.0102
1,000	0.9433	0.6413	0.0224	0.9749	0.8667	0.0143	0.9949	0.9439	0.0078
2,000	0.9486	0.6879	0.0205	0.9833	0.9026	0.0121	0.9974	0.9687	0.0054
4,000	0.9591	0.7550	0.0189	0.9869	0.9333	0.0078	0.9971	0.9707	0.0046
8,000	0.9669	0.8004	0.0167	0.9912	0.9640	0.0046	0.9982	0.9827	0.0033
16,000	0.9674	0.8003	0.0163	0.9945	0.9712	0.0034	—	—	—
17,167	0.9673	0.7985	0.0163	0.9937	0.9709	0.0034	—	—	—

源文件：results/metrics_full_C_final.csv。n 为训练例数；测试集固定为 4,292 例/187 事件（full）或 2,729 例/178 事件（dedup）。

表 2-6 特征集 C，去重队列：全部训练规模的指标（n = 100–10,915）

	Logistic regression			LightGBM			TabPFN v2		
n_train	AUROC	AUPRC	Brier	AUROC	AUPRC	Brier	AUROC	AUPRC	Brier
100	0.8126	0.4023	0.0475	0.6626	0.0974	0.0631	0.9063	0.6449	0.0379
250	0.8981	0.5494	0.0398	0.8712	0.5933	0.0473	0.9685	0.8320	0.0226
500	0.9373	0.6813	0.0327	0.9492	0.7844	0.0277	0.9817	0.8843	0.0192
1,000	0.9520	0.7416	0.0294	0.9803	0.8753	0.0204	0.9914	0.9337	0.0135
2,000	0.9574	0.7738	0.0278	0.9841	0.9065	0.0179	0.9966	0.9693	0.0097
4,000	0.9657	0.7988	0.0260	0.9914	0.9467	0.0121	0.9983	0.9834	0.0067
8,000	0.9695	0.8070	0.0248	0.9960	0.9730	0.0080	0.9988	0.9880	0.0048
10,915	0.9699	0.8098	0.0241	0.9976	0.9798	0.0062	—	—	—

源文件：results/metrics_dedup_C_final.csv。n 为训练例数；测试集固定为 4,292 例/187 事件（full）或 2,729 例/178 事件（dedup）。

全队列：LR 从 n = 100 的 0.8779 升到 n = 17,167 的 0.9673；LGBM 从 0.5639 升到 0.9937；TabPFN 在 n = 100 已达 0.9440，n = 8,000 为 0.9982。全表最高值出现在 TabPFN、n = 8,000（0.9982）。去重队列（n = 100–10,915）的形态相同：LR 0.8126 → 0.9699；LGBM 0.6626 → 0.9976；TabPFN 0.9063 → 0.9988。

把六张表放在一起看，能读出三条跨特征集的稳定规律。第一，LR 的学习曲线最平：从 100 例到全量，涨幅约 0.09–0.24 AUROC，而 LGBM 在 100 例时几乎等于随机（0.5000–0.6626），到全量才追上来。第二，TabPFN 的曲线在前段最高、后段趋平：100 例时比 LGBM 高 0.24–0.38，8,000 例时与 LGBM 的差距缩到 0.001–0.007。第三，去重没有改变排序，只把绝对水平移动了 −0.002 到 +0.004，说明重复记录不是结论的来源。

唯一的例外值得单独指出：在特征集 A 上，LGBM 用 16,000 例达到 0.9464，略高于 TabPFN 在 8,000 例上限的 0.9445。这不是“树模型更好”，而是 TabPFN 被上下文长度限制在 8,000——给它同样的 16,000 例，比较才公平，而当前实现做不到。B/C 上 TabPFN 在 8,000 例已经足够领先，所以这个上限不构成实际限制；在信息较少的 A 上，它恰好落在临界点。

3　主结果：n = 8,000 与全训练集锚点

如果只看一张表，就看表 3-1。它给出 n = 8,000（三模型共同可用的最大规模）下，A/B/C × full/dedup × 三模型的 AUROC 与 2,000 次配对 bootstrap 的 95% 区间。区间来自同一批测试患者的配对重抽样，因此可以直接比较重叠程度。

表 3-1　n = 8,000 的主结果（AUROC / AUPRC / Brier，括号内为 95% CI）

模型	AUROC（95% CI）	AUPRC（95% CI）	Brier（95% CI）	校准斜率
特征集 A · 全队列				
LR	0.8553（0.8254, 0.8827）	0.2171（0.1753, 0.2683）	0.0396（0.0345, 0.0446）	0.846
LGBM	0.9378（0.9188, 0.9538）	0.5785（0.5052, 0.6535）	0.0450（0.0407, 0.0495）	0.677
TabPFN	0.9445（0.9281, 0.9605）	0.6293（0.5608, 0.6941）	0.0248（0.0211, 0.0285）	0.947
特征集 A · 去重队列				
LR	0.8724（0.8458, 0.8947）	0.3208（0.2651, 0.3876）	0.0527（0.0462, 0.0595）	0.990
LGBM	0.9282（0.9091, 0.9444）	0.5935（0.5132, 0.6668）	0.0674（0.0606, 0.0747）	0.681
TabPFN	0.9309（0.9151, 0.9441）	0.5955（0.5250, 0.6622）	0.0391（0.0339, 0.0449）	0.897
特征集 B · 全队列				
LR	0.9625（0.9420, 0.9798）	0.7753（0.7115, 0.8329）	0.0173（0.0142, 0.0205）	0.965
LGBM	0.9923（0.9855, 0.9976）	0.9603（0.9359, 0.9810）	0.0050（0.0032, 0.0070）	0.706
TabPFN	0.9980（0.9954, 0.9996）	0.9821（0.9673, 0.9936）	0.0037（0.0022, 0.0053）	1.024
特征集 B · 去重队列				
LR	0.9660（0.9496, 0.9792）	0.7944（0.7377, 0.8475）	0.0261（0.0214, 0.0309）	0.993
LGBM	0.9964（0.9933, 0.9988）	0.9736（0.9570, 0.9873）	0.0078（0.0051, 0.0109）	0.815
TabPFN	0.9985（0.9972, 0.9996）	0.9861（0.9739, 0.9954）	0.0050（0.0030, 0.0073）	1.153
特征集 C · 全队列				
LR	0.9669（0.9481, 0.9824）	0.8004（0.7465, 0.8502）	0.0167（0.0140, 0.0198）	0.994
LGBM	0.9912（0.9830, 0.9973）	0.9640（0.9396, 0.9829）	0.0046（0.0029, 0.0066）	0.712
TabPFN	0.9982（0.9964, 0.9996）	0.9827（0.9687, 0.9937）	0.0033（0.0019, 0.0049）	0.966
特征集 C · 去重队列				
LR	0.9695（0.9537, 0.9820）	0.8070（0.7501, 0.8567）	0.0248（0.0205, 0.0296）	1.006
LGBM	0.9960（0.9920, 0.9987）	0.9730（0.9544, 0.9872）	0.0080（0.0054, 0.0111）	0.800
TabPFN	0.9988（0.9977, 0.9996）	0.9880（0.9782, 0.9957）	0.0048（0.0029, 0.0070）	1.240

源文件：results/restore/ci.json（区间）与 bench_summary_final.json（斜率）。测试集：full 4,292 例/187 事件；dedup 2,729 例/178 事件。

三条读数。第一，在 B/C 上 TabPFN 的 AUROC 为 0.9980 / 0.9982（full），区间下界 0.9954 / 0.9964，已经贴近该测试集可分辨的上限；LGBM 紧随其后（0.9923 / 0.9912），LR 明显更低（0.9625 / 0.9669）。第二，在 A 上三模型 closer：TabPFN 0.9445、LGBM 0.9378、LR 0.8553；TabPFN 对 LGBM 的配对差为 +0.0067（−0.0021, +0.0159），区间跨零——在只有 36 个入院特征时，两者的差别不足以在 4,292 例测试集上稳定检出。第三，去重后排序不变：A 为 TabPFN 0.9309 > LGBM 0.9282 > LR 0.8724；B 为 0.9985 / 0.9964 / 0.9660；C 为 0.9988 / 0.9960 / 0.9695。

表 3-2　全训练集锚点（LR 与 LGBM 用满训练集；TabPFN 标 † 者为 8,000 上限）

模型	n_train	AUROC	AUPRC	Brier	校准斜率
特征集 A · 全队列					
LR	17,167	0.8618	0.2271	0.0396	0.858
LGBM	17,167	0.9460	0.6110	0.0567	0.846
TabPFN †	8,000	0.9445	0.6293	0.0248	0.947
特征集 A · 去重队列					
LR	10,915	0.8731	0.3235	0.0526	0.955
LGBM	10,915	0.9328	0.6053	0.0713	0.726
TabPFN †	8,000	0.9309	0.5955	0.0391	0.897
特征集 B · 全队列					
LR	17,167	0.9648	0.7872	0.0167	1.018
LGBM	17,167	0.9956	0.9705	0.0038	0.731
TabPFN †	8,000	0.9980	0.9821	0.0037	1.024
特征集 B · 去重队列					
LR	10,915	0.9663	0.7994	0.0254	0.996
LGBM	10,915	0.9963	0.9764	0.0066	0.835
TabPFN †	8,000	0.9985	0.9861	0.0050	1.153
特征集 C · 全队列					
LR	17,167	0.9673	0.7985	0.0163	1.038
LGBM	17,167	0.9937	0.9709	0.0034	0.732
TabPFN †	8,000	0.9982	0.9827	0.0033	0.966
特征集 C · 去重队列					
LR	10,915	0.9699	0.8098	0.0241	1.003
LGBM	10,915	0.9976	0.9798	0.0062	0.872
TabPFN †	8,000	0.9988	0.9880	0.0048	1.240

源文件：metrics_{full,dedup}_{A,B,C}_final.csv 的最大 n 行；斜率来自 table_numbers.json 的 slope_*_fullsize。† TabPFN 无法在 8,000 以上运行，此行为 8,000 例估计，不是全量估计。

这张表回答“再多给数据还有没有用”。A 上 LGBM 从 8,000 的 0.9378 升到 17,167 的 0.9460（+0.0082），说明入院特征仍有可学的余量；B 上 LGBM 从 0.9923 升到 0.9956（+0.0033），已接近天花板；C 上 LGBM 从 0.9912 升到 0.9937（+0.0025），但仍低于 B 的 0.9956——并发症块没有带来信息，还轻微稀释了模型。LR 的对应变化是 A +0.0065、B +0.0023、C +0.0004（8,000 → 最大 n）。

注意 TabPFN 的两行不是“全量”结果：其上下文上限为 8,000，表中数值与上一张表的 8,000 行相同。本书在所有出现 † 的地方都保持这一约定，避免把 8,000 的估计误读成 17,167 的结果。

3.1 计算成本

同一台服务器、同一批 CPU 上的墙钟时间（拟合 + 预测一次）。这不是 benchmarking 级别的精确计时，但足以回答临床落地时最现实的问题：训练一次要等多久。

表 3-3　n = 8,000 时的单次拟合+预测耗时（秒）

模型	秒	相对 LR
特征集 A · 全队列		
LR	0.02	1×
LGBM	0.22	10×
TabPFN	159.30	7019×
特征集 A · 去重队列		
LR	0.02	1×
LGBM	0.23	9×
TabPFN	131.97	5369×
特征集 B · 全队列		
LR	0.08	1×
LGBM	0.36	5×
TabPFN	304.07	3955×
特征集 B · 去重队列		
LR	0.09	1×
LGBM	0.49	5×
TabPFN	295.91	3289×
特征集 C · 全队列		
LR	0.09	1×
LGBM	0.36	4×
TabPFN	316.06	3402×
特征集 C · 去重队列		
LR	0.08	1×
LGBM	0.40	5×
TabPFN	311.23	3719×

源文件：metrics_*_final.csv 的 fit_predict_seconds 列。单次运行、共享服务器、CPU；未做重复计时。

LR 与 LGBM 都在 1 秒以内；TabPFN 在 CPU 上需要 2–5 分钟，是 LR 的数千倍。这个成本差是真实的：TabPFN 的优势要用“更少样本达到同样性能”来兑换，而不是免费获得。在 B/C 上它用 500 例追平 LGBM 8,000 例，省下的是数据与标注，不是算力。

4 校准与决策曲线

判别力只回答“排序对不对”，校准回答“概率能不能直接拿给患者看”。校准斜率 < 1 表示模型把概率推得过散（高估高风险、低估低风险），> 1 表示推得过于集中。表中同时给出 n = 8,000 与全训练集的斜率，以及对应的 Brier 分数。

表 4-1　全队列的校准（n = 8,000 与全训练集）

模型	斜率@8,000	截距@8,000	斜率@全量	Brier@8,000	Brier@全量
特征集 A					
LR	0.846	-0.412	0.858	0.0396	0.0396
LGBM	0.677	-1.666	0.846	0.0450	0.0567
TabPFN	0.947	+0.081	0.947	0.0248	0.0248
特征集 B					
LR	0.965	-0.056	1.018	0.0173	0.0167
LGBM	0.706	+0.347	0.731	0.0050	0.0038
TabPFN	1.024	+1.360	1.024	0.0037	0.0037
特征集 C					
LR	0.994	-0.011	1.038	0.0167	0.0163
LGBM	0.712	+0.368	0.732	0.0046	0.0034
TabPFN	0.966	+0.959	0.966	0.0033	0.0033

源文件：bench_summary_final.json（8,000）与 table_numbers.json（全量斜率）、metrics_*_final.csv（Brier）。† TabPFN 的“全量”列仍为 8,000 估计。

表 4-2　去重队列的校准（n = 8,000 与全训练集）

模型	斜率@8,000	截距@8,000	斜率@全量	Brier@8,000	Brier@全量
特征集 A					
LR	0.990	-0.049	0.955	0.0527	0.0526
LGBM	0.681	-1.684	0.726	0.0674	0.0713
TabPFN	0.897	-0.137	0.897	0.0391	0.0391
特征集 B					
LR	0.993	+0.095	0.996	0.0261	0.0254
LGBM	0.815	+0.476	0.835	0.0078	0.0066
TabPFN	1.153	+0.758	1.153	0.0050	0.0050
特征集 C					
LR	1.006	+0.108	1.003	0.0248	0.0241
LGBM	0.800	+0.504	0.872	0.0080	0.0062
TabPFN	1.240	+0.840	1.240	0.0048	0.0048

源文件：bench_summary_final.json（8,000）与 table_numbers.json（全量斜率）、metrics_*_final.csv（Brier）。† TabPFN 的“全量”列仍为 8,000 估计。

LightGBM 的斜率在六个组合中全部低于 0.85（0.677–0.815），是系统性的概率压缩：它排序很好，但输出的概率偏保守/过度自信，直接用于个体风险沟通会失真。LR 除 A-full 的 0.846 外都在 0.96–1.01，校准接近恒等；TabPFN 在 0.897–1.240 之间，B/C 的去重队列略高于 1（1.15 / 1.24），说明它在极低风险区的概率被推得过于集中——这是接近完美判别时校准斜率不稳定的典型表现，不应解读为“校准变差”。

全训练集上的斜率进一步放大这一模式：B/C 的 LR 与 TabPFN 斜率都略高于 1（1.02–1.04 与 1.02–1.24），因为测试集里几乎没有中间风险的患者，logistic 斜率对少数极端概率非常敏感。结论不变：若要把概率用于临床，LR 与 TabPFN 可直接使用，LGBM 需要先做校准（Platt 或 isotonic）。

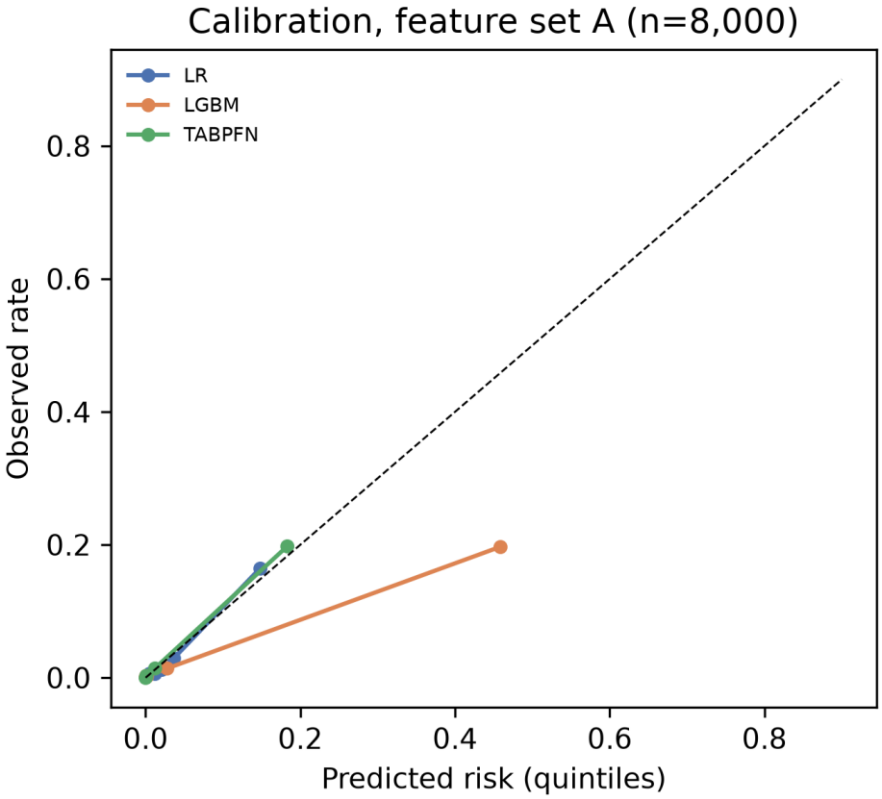


图 4-1　特征集 A 在 n = 8,000 下的校准曲线（按预测风险五分位）

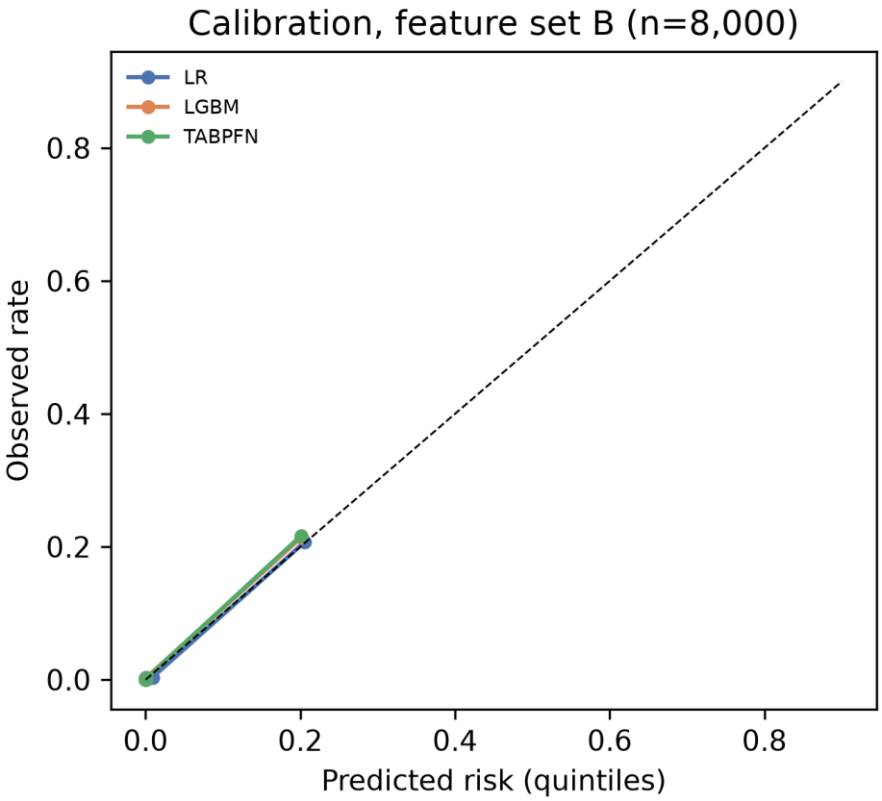


图 4-2　特征集 B 在 n = 8,000 下的校准曲线（按预测风险五分位）

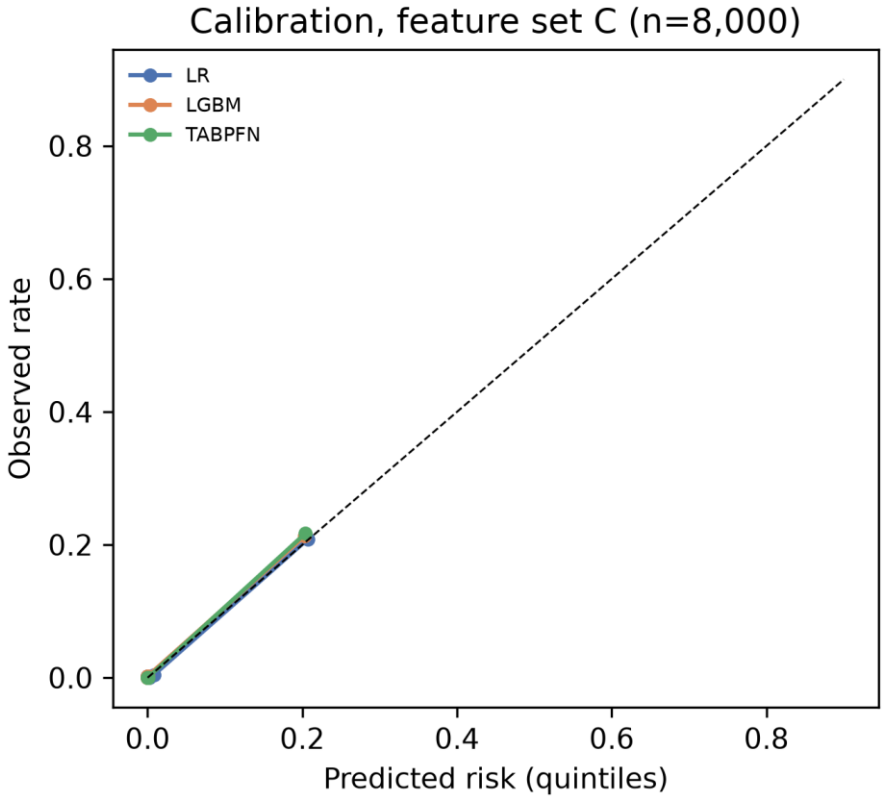


图 4-3　特征集 C 在 n = 8,000 下的校准曲线（按预测风险五分位）

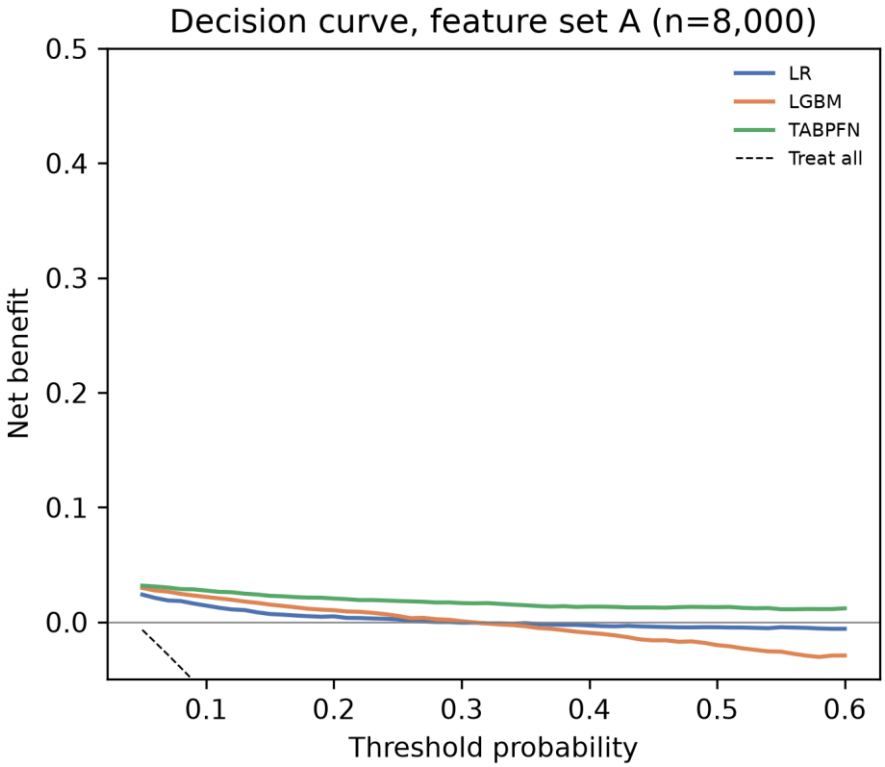


图 4-4　特征集 A 在 n = 8,000 下的决策曲线（阈值 0.05–0.60）

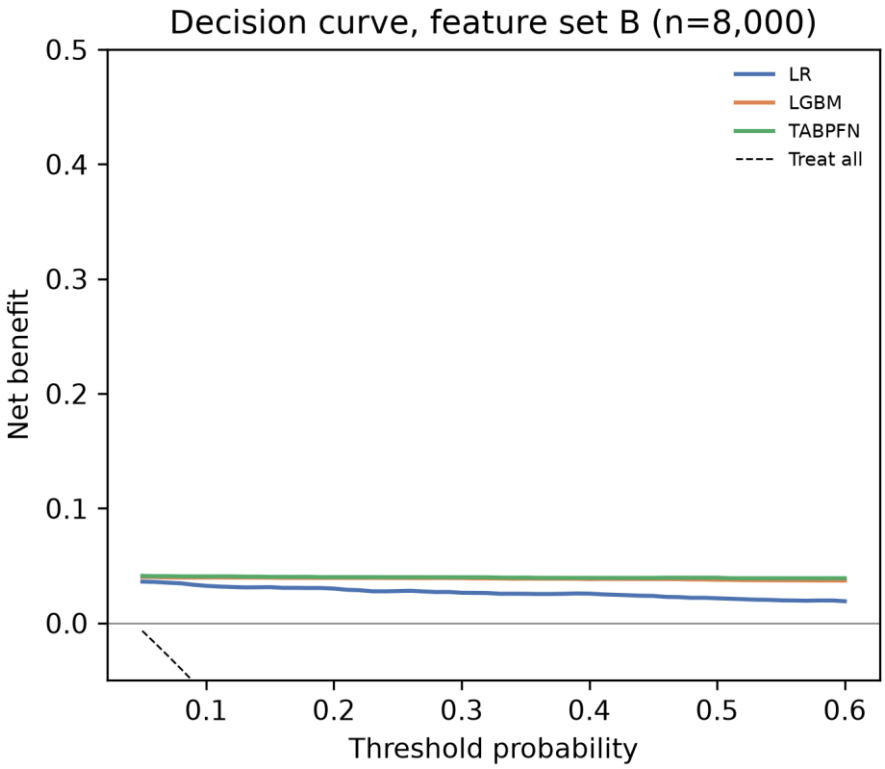


图 4-5　特征集 B 在 n = 8,000 下的决策曲线（阈值 0.05–0.60）

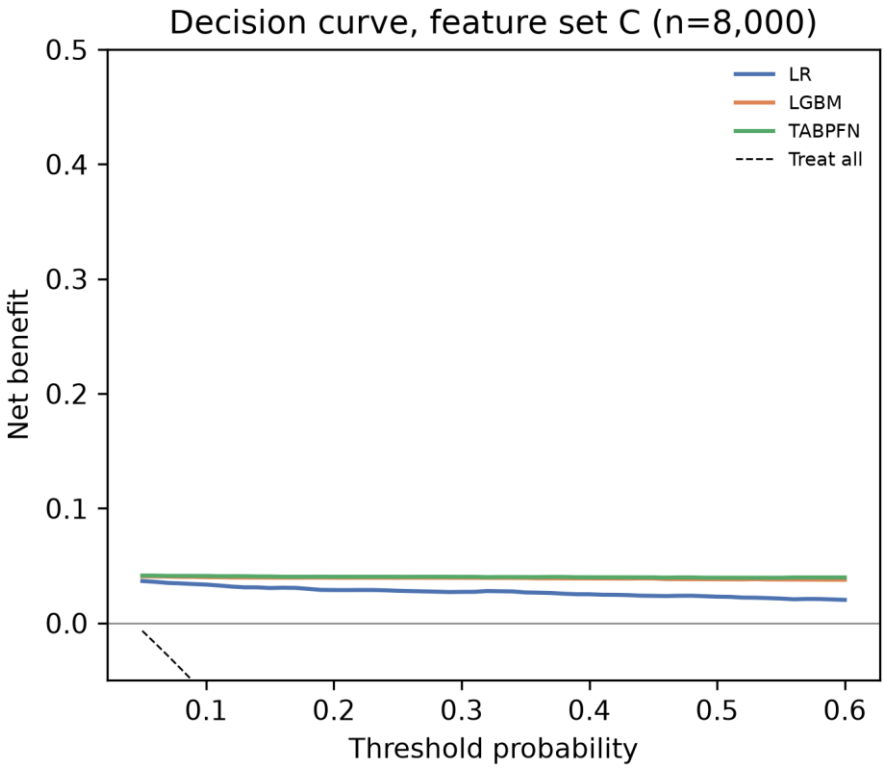


图 4-6　特征集 C 在 n = 8,000 下的决策曲线（阈值 0.05–0.60）

决策曲线的读法：在某个阈值上，曲线高于“全治”与“不治”两条参考线，才说明按模型分流有净获益。B/C 上 TabPFN 在绝大多数阈值上最高；A 上三模型在 0.10–0.30 区间接近，LGBM 在中段略优。校准与决策曲线的完整像素级结果见 results/figs/。

5 增量与配对比较

本节回答两个问题：加一个特征块值不值（A→B、B→C）；换一个模型值不值（TabPFN vs LGBM vs LR）。所有差值都在同一批测试患者上计算，区间来自 2,000 次配对 bootstrap。

5.1 特征块增量

表 5-1　特征块带来的 ΔAUROC（n = 8,000；括号内为 95% CI）

对比	队列	LR	LGBM	TabPFN
A → B（加实验室）	全队列	+0.1072（+0.0855, +0.1307）	+0.0544（+0.0406, +0.0702）	+0.0535（+0.0388, +0.0695）
A → B（加实验室）	去重队列	+0.0936（+0.0737, +0.1153）	+0.0683（+0.0520, +0.0845）	+0.0676（+0.0526, +0.0832）
B → C（加并发症）	全队列	+0.0043（+0.0008, +0.0084）	-0.0010（-0.0029, +0.0005）	+0.0002（-0.0004, +0.0011）
B → C（加并发症）	去重队列	+0.0035（-0.0000, +0.0075）	-0.0004（-0.0022, +0.0008）	+0.0003（-0.0001, +0.0008）

源文件：results/table_numbers.json（delta_AB_*、delta_B_minus_A_*、delta_CB_*）。正值为加入新特征块后 AUROC 升高。

实验室块是唯一大幅改变判别力的增量：LR +0.1072、LGBM +0.0544、TabPFN +0.0535（full），三个区间都不含零；去重后同向且幅度相近（+0.0936 / +0.0683 / +0.0676）。这个增量在 LR 上最大，因为线性模型从新信息中获益最多；对已经很强的 LGBM/TabPFN，增益相对小，但仍然真实。

并发症块的增量则是噪声级别：LR +0.0043（+0.0008, +0.0084），LGBM −0.0011（−0.0029, +0.0005），TabPFN +0.0002（−0.0004, +0.0011）。只有 LR 的区间排除零，但 0.0043 仅为实验室块增量（0.1072）的二十五分之一，且低于任何合理的临床意义阈值。去重后 LR 的区间甚至触及零（−0.00005, +0.00745）。结论是清楚的：四个卒中后并发症变量在 70 个基线+实验室特征之外没有增量价值。

5.2 模型之间的配对差

表 5-2　同一测试集上的 ΔAUROC（n = 8,000；括号内为 95% CI）

对比	ΔAUROC（95% CI）	区间跨零
特征集 A · 全队列		
TabPFN − LGBM	+0.0067（-0.0021, +0.0159）	是
TabPFN − LR	+0.0892（+0.0718, +0.1090）	否
LGBM − LR	+0.0825（+0.0627, +0.1038）	否
特征集 A · 去重队列		
TabPFN − LGBM	+0.0028（-0.0074, +0.0127）	是
TabPFN − LR	+0.0586（+0.0415, +0.0765）	否
LGBM − LR	+0.0557（+0.0375, +0.0742）	否
特征集 B · 全队列		
TabPFN − LGBM	+0.0057（+0.0017, +0.0110）	否
TabPFN − LR	+0.0352（+0.0187, +0.0544）	否
LGBM − LR	+0.0295（+0.0161, +0.0458）	否
特征集 B · 去重队列		
TabPFN − LGBM	+0.0021（+0.0001, +0.0050）	否
TabPFN − LR	+0.0325（+0.0198, +0.0480）	否
LGBM − LR	+0.0304（+0.0193, +0.0438）	否
特征集 C · 全队列		
TabPFN − LGBM	+0.0069（+0.0019, +0.0138）	否
TabPFN − LR	+0.0312（+0.0165, +0.0493）	否
LGBM − LR	+0.0243（+0.0128, +0.0386）	否
特征集 C · 去重队列		
TabPFN − LGBM	+0.0028（+0.0003, +0.0062）	否
TabPFN − LR	+0.0293（+0.0178, +0.0439）	否
LGBM − LR	+0.0265（+0.0165, +0.0388）	否

源文件：bench_summary_final.json 的 delta_auroc_* 字段。跨零 = 95% 区间包含 0，差异不能在 5% 水平上检出。

三条结论。第一，TabPFN 相对 LR 的优势在所有六个组合中都统计上可检出（最小 +0.0293，区间 +0.0178 至 +0.0439，C-dedup）。第二，TabPFN 相对 LGBM 的优势在 B/C 上可检出（B full +0.0057 [0.0017, 0.0110]；C full +0.0069 [0.0019, 0.0138]），在 A 上不可检出（+0.0067 [−0.0021, +0.0159]）。第三，LGBM 相对 LR 的优势在所有组合中都可检出，幅度 0.024–0.083——树模型比线性模型更适合这套特征。

5.3 数据效率：TabPFN 用多少例追平 LGBM

定义：以 LGBM 在 n = 8,000 的 AUROC 为基准，允许 −0.002 的容差，找 TabPFN 首次达到该水平的最小训练规模。这是对“小样本优势”最直接、也最不容易夸大的量化。

表 5-3　TabPFN 追平 LGBM（8,000 例水平）所需的最小 n

组合	LGBM@8,000	TabPFN 最小 n	TabPFN@该 n	差值
特征集 A · 全队列	0.9378	4,000	0.9424	+0.0045
特征集 A · 去重队列	0.9282	4,000	0.9275	-0.0007
特征集 B · 全队列	0.9923	500	0.9911	-0.0012
特征集 B · 去重队列	0.9964	2,000	0.9965	+0.0000
特征集 C · 全队列	0.9912	500	0.9907	-0.0005
特征集 C · 去重队列	0.9960	2,000	0.9966	+0.0006

源文件：bench_summary_final.json 的 tabpfn_n_to_match_lgbm_at_8000；定义为 TabPFN AUROC ≥ LGBM@8,000 − 0.002 的最小 n。

B/C 全队列只需 500 例就进入容差（0.9911 / 0.9907 vs 0.9923 / 0.9912），去重队列需 2,000 例；A 需要 4,000 例（0.9424，已超过 LGBM@8,000 的 0.9378）。换成比例：在 B/C 上，TabPFN 用 6.25% 的训练数据达到 LGBM 用满 8,000 例的水平；在 A 上这个比例是 50%。信息越少的问题，预训练先验越值钱——这与“小样本优势来自先验而非数据”的解释一致。

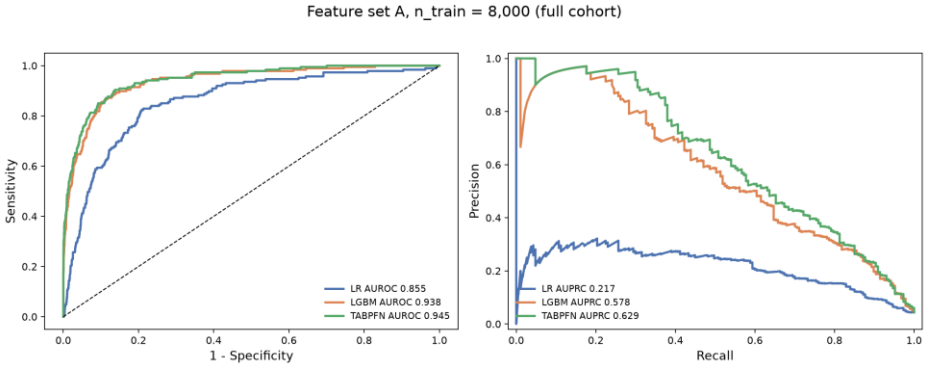


图 5-1　特征集 A 在 n = 8,000 下的 ROC 与 PR 曲线（全队列）

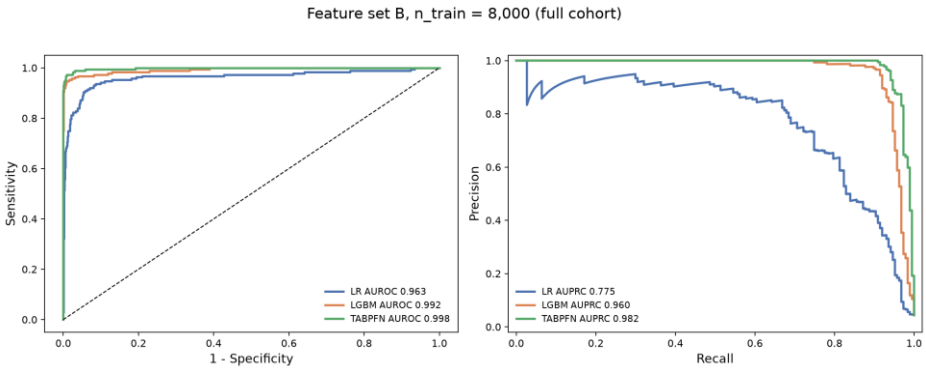


图 5-2　特征集 B 在 n = 8,000 下的 ROC 与 PR 曲线（全队列）

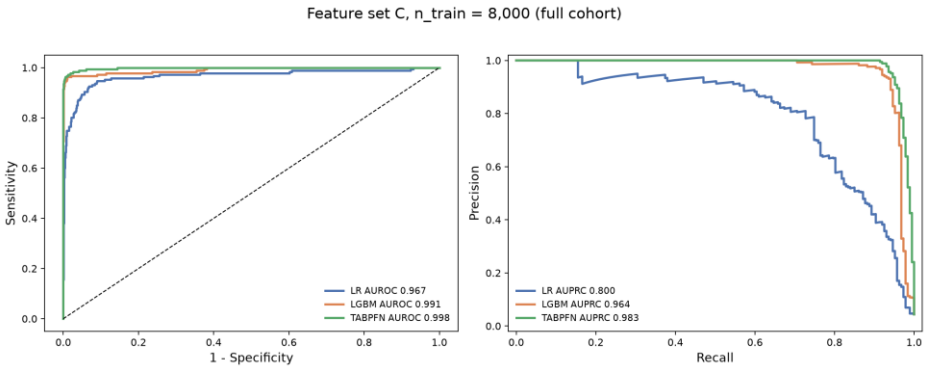


图 5-3　特征集 C 在 n = 8,000 下的 ROC 与 PR 曲线（全队列）

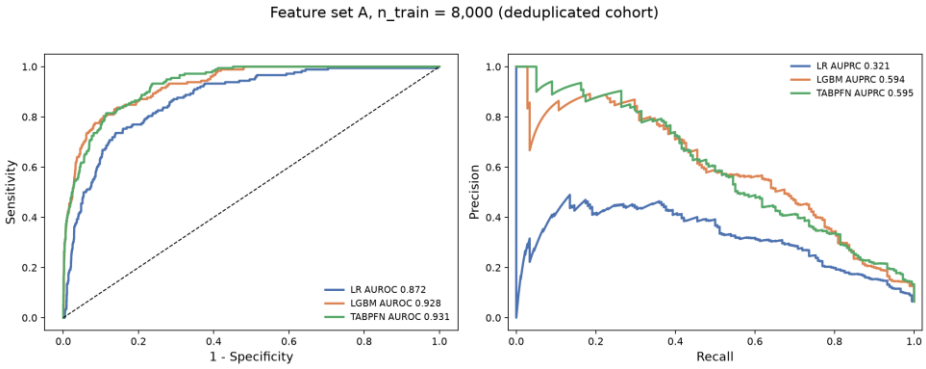


图 5-4　特征集 A 在 n = 8,000 下的 ROC 与 PR 曲线（去重队列）

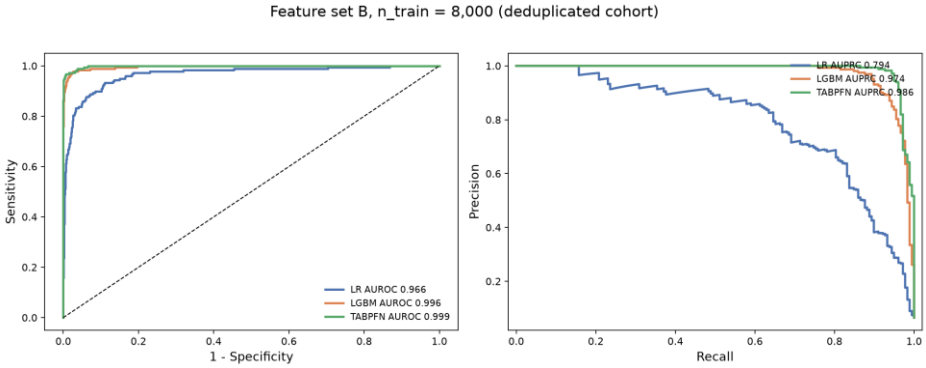


图 5-5　特征集 B 在 n = 8,000 下的 ROC 与 PR 曲线（去重队列）

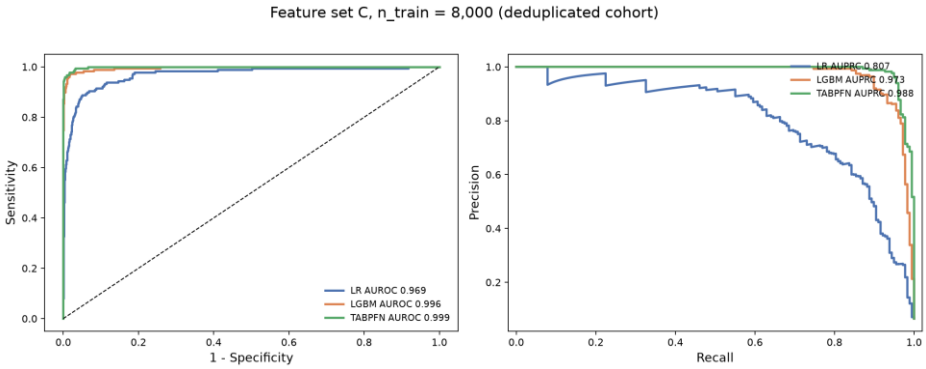


图 5-6　特征集 C 在 n = 8,000 下的 ROC 与 PR 曲线（去重队列）

6　特征重要性：A / B / C 的前十变量

重要性用两种口径：LGBM 的总增益份额（gain share，所有树分裂带来的不纯度下降占比，加总为 100%），以及标准化 LR 的系数绝对值。两者不可直接比较——增益份额是相对量，系数是每标准差变化的 log-odds——但各自内部可以排序。下表列出每个特征集的前十，右侧同时给出另一模型的前十，便于对照。

表 6-1　特征集 A（36 个变量）的前十重要性

排名	LGBM 变量	增益份额	LR 变量	|系数|
1	NIHSS 评分	49.99%	岛叶	1.68
2	年龄	17.53%	NIHSS 评分	1.30
3	高血压	6.66%	高尿酸血症	0.91
4	冠心病	2.66%	半卵圆中心	0.76
5	性别（男=1）	2.64%	冠心病	0.74
6	高尿酸血症	2.42%	性别（男=1）	0.73
7	皮层下	2.29%	糖尿病	0.62
8	糖尿病	1.96%	大脑中动脉供血区	0.58
9	高脂血症	1.50%	尿毒症	0.55
10	脑室旁	1.39%	高血压	0.54

源文件：results/restore/restore.json 的 importance.A。模型在全训练集（17,167 例）上重拟合；LGBM 测试 AUROC 0.9460，LR 测试 AUROC 0.8618。

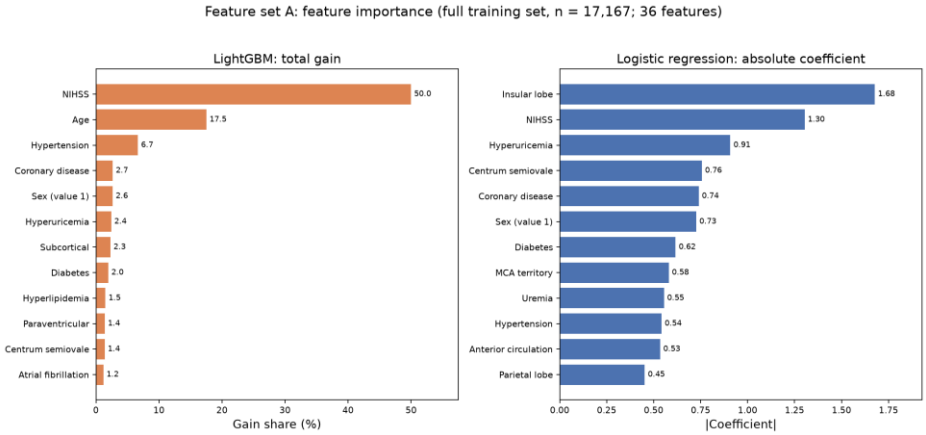


图 6-1　特征集 A 的特征重要性：LightGBM 总增益（左）与 LR 系数绝对值（右）

表 6-2　特征集 B（70 个变量）的前十重要性

排名	LGBM 变量	增益份额	LR 变量	|系数|
1	NIHSS 评分	29.54%	D-二聚体	3.84
2	白细胞	9.75%	高血压	3.23
3	C 反应蛋白	7.64%	C 反应蛋白	3.03
4	α-羟丁酸脱氢酶	6.09%	谷草转氨酶	2.99
5	谷草转氨酶	5.20%	CK-MB	2.25
6	糖化血红蛋白	3.96%	甘油三酯	2.13
7	D-二聚体	3.42%	白细胞	1.65
8	乳酸	3.25%	椎动脉供血区	1.58
9	甘油三酯	3.15%	NIHSS 评分	1.23
10	肌酸激酶	2.98%	大脑前动脉供血区	1.09

源文件：results/restore/restore.json 的 importance.B。模型在全训练集（17,167 例）上重拟合；LGBM 测试 AUROC 0.9956，LR 测试 AUROC 0.9647。

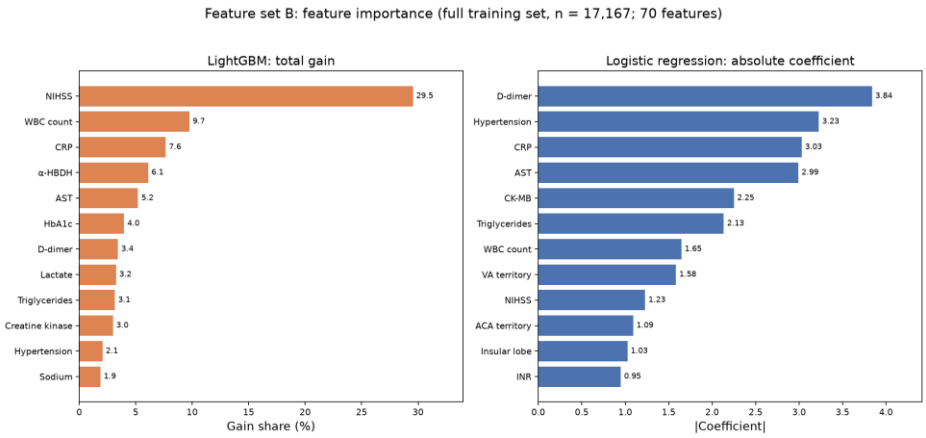


图 6-2　特征集 B 的特征重要性：LightGBM 总增益（左）与 LR 系数绝对值（右）

表 6-3　特征集 C（74 个变量）的前十重要性

排名	LGBM 变量	增益份额	LR 变量	|系数|
1	CK-MB	18.68%	D-二聚体	4.04
2	NIHSS 评分	14.91%	高血压	3.27
3	C 反应蛋白	12.56%	谷草转氨酶	3.07
4	α-羟丁酸脱氢酶	6.44%	C 反应蛋白	2.66
5	乳酸	4.90%	CK-MB	2.47
6	D-二聚体	3.52%	甘油三酯	1.81
7	肌酸激酶	3.39%	椎动脉供血区	1.72
8	白细胞	3.25%	白细胞	1.60
9	谷草转氨酶	3.20%	脑积水	1.27
10	钠	2.28%	大脑前动脉供血区	1.22

源文件：results/restore/restore.json 的 importance.C。模型在全训练集（17,167 例）上重拟合；LGBM 测试 AUROC 0.9937，LR 测试 AUROC 0.9675。

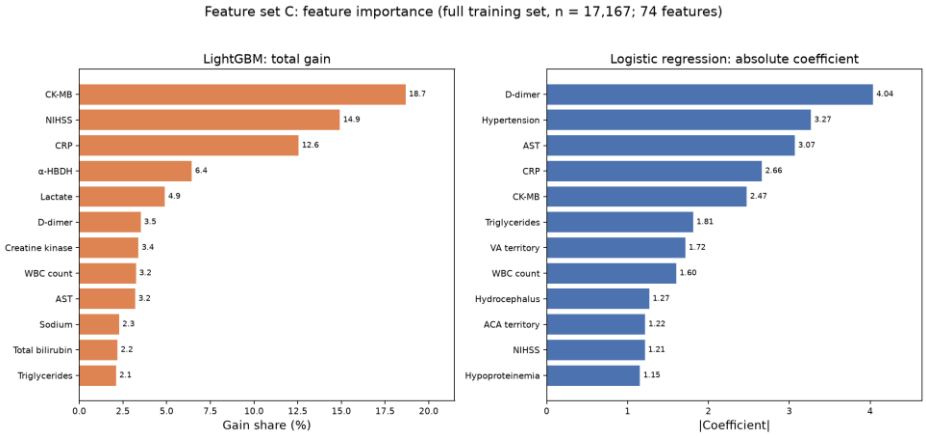


图 6-3　特征集 C 的特征重要性：LightGBM 总增益（左）与 LR 系数绝对值（右）

A 的信息高度集中：NIHSS 单独占 LGBM 增益的 49.99%，年龄 17.53%，高血压 6.66%，其余变量都在 3% 以下；LR 的口径更分散，岛叶（1.68）、NIHSS（1.30）、高尿酸血症（0.91）排前三。这解释了 A 的学习曲线为什么最陡：模型主要在学习“NIHSS 越高越危险”这一条主轴。

B 把重要性重新分配：NIHSS 降到 29.54%，白细胞 9.75%、C 反应蛋白 7.64%、α-羟丁酸脱氢酶 6.09%、谷草转氨酶 5.20% 进入前五；LR 侧则是 D-二聚体（3.84）、高血压（3.23）、C 反应蛋白（3.03）、谷草转氨酶（2.99）。实验室指标不是“锦上添花”，它们确实承担了相当一部分判别信息。

C 的变化最能说明问题：加入四个并发症变量后，LGBM 的增益重心转到 CK-MB（18.68%）、NIHSS（14.91%）、C 反应蛋白（12.56%）、α-羟丁酸脱氢酶（6.44%）与乳酸（4.90%）；四个并发症变量在 LGBM 中排名第 45（深静脉血栓）、74（脑疝）、65（脑积水）、35（低蛋白血症），全部在后半段。LR 中脑积水（第 9）与低蛋白血症（第 12）进入中上段，深静脉血栓（第 19）、脑疝（第 25）居中——这四项的单变量关联很强（第 3.1 节表 1），但在 70 个特征之外能提供的增量几乎为零。单变量关联与增量价值是两个不同的量。

7　特征集 A 的五折交叉验证与 OOF

主分析用的是固定 80/20 划分。为了确认 A 的结果不是某一次划分的偶然，另做一次 5 折分层交叉验证（在 17,167 例训练集内部，种子 42），并汇总折外预测（OOF）。OOF 指标与“折均值”不完全相同：前者把所有折的预测拼成一份完整训练集的预测，后者是五个折指标的算术平均。

表 7-1　特征集 A 的 5 折交叉验证（训练集内部）

模型	AUROC（折均值±SD）	AUPRC	Brier	OOF AUROC	OOF AUPRC	OOF Brier
LR	0.8849 ± 0.0165	0.2572 ± 0.0221	0.0382 ± 0.0014	0.8848	0.2508	0.0382
LGBM	0.9461 ± 0.0099	0.5826 ± 0.0337	0.0555 ± 0.0033	0.9459	0.5754	0.0555

源文件：results/restore/restore.json 的 cv_A。5 折、单次重复；OOF = 折外预测拼接后整体计算。

CV 的数值高于固定测试集（LR 0.8849 vs 0.8553；LGBM 0.9461 vs 0.9378），原因不是模型变了，而是评估对象不同：CV 在训练集内部做，测试折与训练折来自同一分布且没有留出整个 20% 的固定测试集；固定测试集是更严格、也更接近外部验证的口径。两者都报告，是为了让读者看到“划分带来的不确定性”有多大——约 0.01–0.03 AUROC，远大于模型之间的部分差距。任何小于这个量级的模型比较都应谨慎解读。

8　D 研究：温州 167 例的首次发作时点预测

D 研究换了队列与临床问题：167 例卒中后早期癫痫发作患者（PSE 49 例，29.3%；中位随访 592 天），在“首次发作之后”这个决策点预测是否会发展为晚期 PSE。核心特征集只有 8 个变量，扩展集 24 个；评估用 5 折 × 10 重复交叉验证（种子 42）。因此它的数字不能与 A/B/C 横向比较，只能在本节内部比较。

8.1　队列基线

表 8-1　温州队列基线（总体、无 PSE、PSE）

指标	总体（n = 167）	无 PSE（n = 118）	PSE（n = 49）
年龄（岁，中位/IQR）	65（58–74）	64.5（57.2–74）	65（59–73）
男性	31.7%	31.4%	32.7%
缺血性卒中	66.5%	67.8%	63.3%
NIHSS（中位/IQR）	6（3–11.5）	5（3–11）	6（3–16）
首次发作距卒中 > 3 天	16.8%	10.2%	32.7%
早期多次发作	12.6%	6.8%	26.5%
癫痫持续状态	26.3%	23.7%	32.7%
皮层受累	85.0%	85.6%	83.7%
EEG 癫痫样放电	21.0%	22.0%	18.4%
病灶体积（cm³，中位/IQR）	9.4（2.7–22.7）	9（3.2–21.4）	9.8（2.5–27.6）
使用 ASM	80.2%	78.8%	83.7%
随访天数（中位/IQR）	592（170.5–1471.5）	992.5（503.5–2046.5）	74（18–199）

源文件：results/table1_wenzhou.json。PSE 组的随访天数为“到首次晚期发作或末次随访”的时间，因此中位数仅 74 天，不能与无 PSE 组直接比较。

两组差异集中在发作本身的信息：首次发作距卒中 > 3 天者 32.7% vs 10.2%，早期多次发作 26.5% vs 6.8%，癫痫持续状态 32.7% vs 23.7%；PSE 组 NIHSS 的上四分位数更高（16 vs 11）。皮层受累与 EEG 癫痫样放电在两组间反而略低（83.7% vs 85.6%；18.4% vs 22.0%），提示这套队列的转归更多由发作时间与复发模式驱动，而不是单纯的病灶严重度。

8.2　交叉验证结果

表 8-2　D 研究 5 折 × 10 重复交叉验证（均值 ± SD）

模型	核心 AUROC	核心 AUPRC	核心 Brier	核心斜率	扩展 AUROC	扩展 AUPRC	扩展 Brier	扩展斜率
LR	0.7101 ± 0.0199	0.5331 ± 0.0264	0.1825 ± 0.0059	0.918	0.6359 ± 0.0364	0.4598	0.2033	0.502
LGBM	0.7018 ± 0.0124	0.4708 ± 0.0184	0.2113 ± 0.0038	0.804	0.6389 ± 0.0206	0.4153	0.2274	0.547
TabPFN	0.6706 ± 0.0235	0.4804 ± 0.0291	0.1901 ± 0.0048	0.939	0.6233 ± 0.0313	0.4261	0.1981	0.873

源文件：results/summary_D.json 的 feature_sets..metrics_mean_std。核心 8 变量、扩展 24 变量；50 个折次。*

核心 8 变量上 LR 最好（AUROC 0.7101，AUPRC 0.5331，Brier 0.1825），LGBM 次之（0.7018），TabPFN 最低（0.6706）。扩展到 24 变量后三个模型全部变差（0.6359 / 0.6389 / 0.6233）——在 n = 167 下，额外 16 个变量带来的是过拟合而不是信息。校准方面 TabPFN 最好（核心斜率 0.939），LGBM 0.804，LR 0.918；扩展集上三者都退化（0.50–0.87）。

8.3　配对差与 ASM 增量

表 8-3　核心特征集上的配对 ΔAUROC（bootstrap 95% CI）

对比	ΔAUROC（95% CI）	区间跨零
TabPFN − LGBM	-0.0383（-0.0943, +0.0145）	是
TabPFN − LR	-0.0565（-0.1090, -0.0058）	否
LR − LGBM	+0.0181（-0.0343, +0.0665）	是

源文件：results/summary_D.json 的 paired_bootstrap_delta_auroc_core。

只有 TabPFN − LR 的区间排除零（−0.0565 [−0.1090, −0.0058]），即 TabPFN 显著更差；TabPFN − LGBM 与 LR − LGBM 的区间都跨零。在小队列里，模型差距的区间本身就很宽，这正是 D 研究反复强调“诚实基准”的原因。

表 8-4　加入 ASM 变量前后的 AUROC（核心集，10 次重复）

模型	不含 ASM	含 ASM	ΔAUROC	Δ>0 的重复次数
LR	0.7101	0.6998	-0.0102	0/10
LGBM	0.7018	0.6994	-0.0024	1/10
TabPFN	0.6706	0.6629	-0.0077	2/10

源文件：results/summary_D.json 的 asm_incremental_core。

三个模型的 Δ 都为负，且 Δ>0 的重复次数只有 0–2/10。ASM 使用不提供增量预测价值；这与 E 研究的结论一致：是否用药主要由发作严重度决定，而严重度已经由核心 8 变量编码。

8.4　风险三分位与生存分层

表 8-5　按模型风险评分三分位的两年无 PSE 生存率

模型	低危（n/事件/2 年）	中危（n/事件/2 年）	高危（n/事件/2 年）	log-rank χ^2	p
LR	56/7/0.889	55/13/0.769	56/29/0.477	25.16	3.4×10^{6}
TabPFN	56/9/0.853	55/14/0.750	56/26/0.524	15.72	3.9×10^{4}

源文件：results/summary_D.json 的 km_risk_tertiles。每格为"组内例数/事件数/两年无 PSE 生存率"。

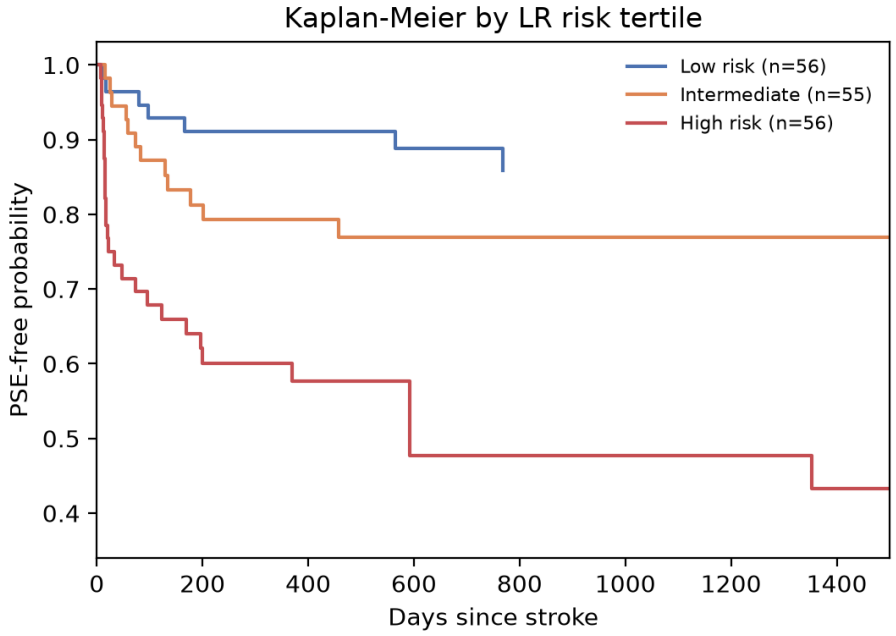


图 8-1　按 LR 风险评分三分位的 Kaplan–Meier 两年无 PSE 生存曲线

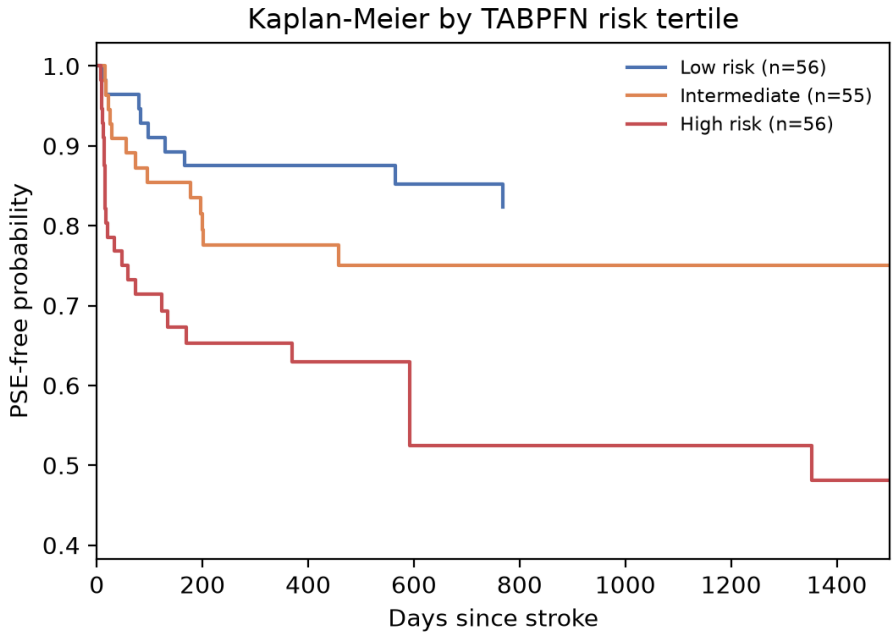


图 8-2　按 TabPFN 风险评分三分位的 Kaplan–Meier 两年无 PSE 生存曲线

LR 三分位的两年无 PSE 生存率为 0.889 / 0.769 / 0.477，log-rank $\chi^2 = 25.16$，$p = 3.4 \times 10^{-6}$；TabPFN 为 0.853 / 0.750 / 0.524，$\chi^2 = 15.72$，$p = 3.9 \times 10^{-4}$。两者都能把风险分层拉开，但 LR 的梯度更陡。注意这是"分层能力"，不是"判别力"——三分位割裂会放大看起来的差异，不能替代 AUROC。

8.5　学习曲线与决策曲线

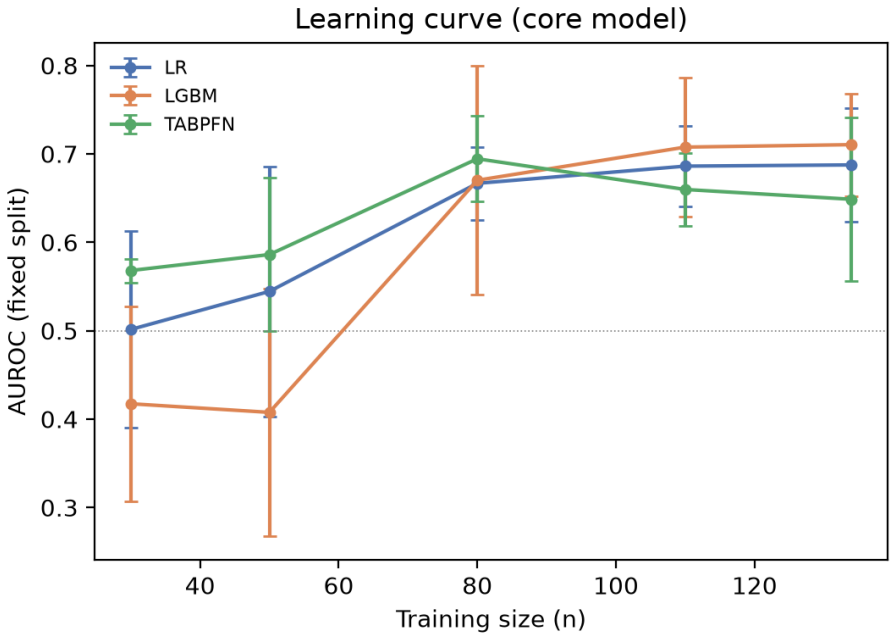


图 8-3　核心特征集上的学习曲线（三个种子均值）：TabPFN 在 n = 30–80 领先，线性模型在全队列规模反超

n = 30 时 TabPFN 0.5681、LR 0.5014、LGBM 0.4174；n = 80 时 TabPFN 0.6944 仍最高；到 n = 134 时 LGBM 0.7104、LR 0.6875，TabPFN 回落到 0.6486。这是全系列中唯一出现“基础模型在小样本领先、随样本增加被反超”完整轨迹的数据集——恰好在 n 只有一两百例时，预训练先验的价值最大，而数据量一旦足够，简单模型的归纳偏置更合适。

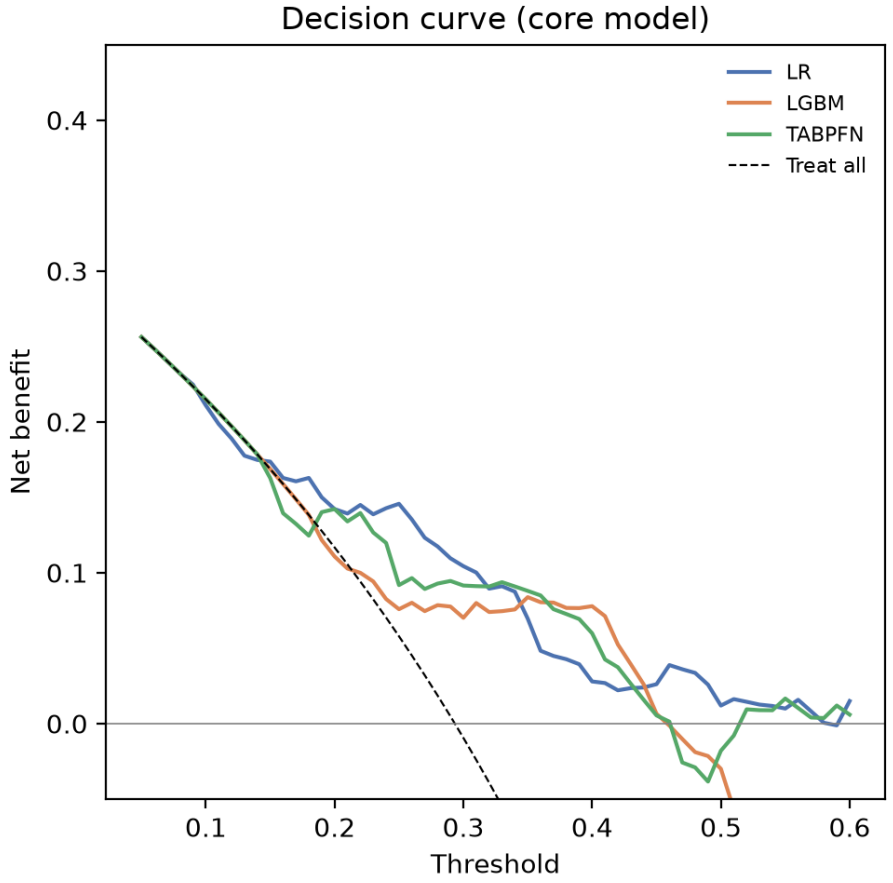


图 8-4　核心特征集三个模型的决策曲线

决策曲线在高阈值段三模型接近；在 0.2–0.4 的临床相关区间，LR 与 LGBM 略高于 TabPFN。结合判别力与校准，D 研究的推荐是 8 变量 LR：不是因为它最“先进”，而是因为它在 n = 167 时最稳、最可解释、校准也足够好。

9　E 研究：抗癫痫药物与晚期 PSE 风险

E 研究是观察性比较，不是预测建模：134 例使用 ASM、33 例未使用，比较随访期内 PSE 的发生风险。由于用药由发作严重度决定，粗比较天然受指征混杂影响；本节给出粗估计、多变量校正、倾向评分校正、IPTW 与 AIPW 五种口径，目的是看结论是否稳健，而不是宣称因果。

9.1　效应估计

表 9-1　ASM 与 PSE 风险的效应估计

方法	估计值	95% CI	备注
粗比值比（OR）	1.378	（0.603, 4.028）	E 值 2.099
多变量校正 OR	1.151	（0.568, 2.693）	E 值 1.569；协变量 9 个
倾向评分校正 OR	1.304	（0.640, 2.763）	PS 作为协变量
IPTW 风险差	+0.00015	（-0.209, +0.207）	PS c 统计量 0.510
AIPW 风险差	-0.0142	（-0.267, +0.203）	增广估计

源文件：results/E/summary_E.json 的 crude / adjusted / ps_adjusted / iptw / aipw。所有区间为 bootstrap 2,000 次。

五个口径的点估计在 0.92–1.38 之间，全部区间跨 1（或风险差跨 0）。没有保护效应的证据，也没有可信的危害信号。E 值 2.10（粗）与 1.57（校正）意味着：需要一个与 ASM 和 PSE 都有约 1.6–2.1 倍关联的未测量混杂因素，才能把观察到的效应完全解释掉——在本领域这并非不可能，因此不能把“无显著”读成“无效应”。

9.2　协变量平衡

表 9-2　倾向评分加权前后的标准化均值差（SMD）

协变量	加权前 SMD	加权后 SMD	|SMD| < 0.1
年龄	+0.132	-0.067	是
sex	-0.042	+0.032	是
stroke_type	-0.005	+0.081	是
NIHSS 评分	-0.020	-0.035	是
status_epilepticus	+0.148	+0.126	否
multiple_seizures	+0.423	+0.102	否
log_lesion_vol	+0.069	-0.101	否
cortical	-0.349	-0.152	否
eeg_epileptic	-0.276	-0.008	是

源文件：results/E/smd_balance.csv。SMD 为 ASM 组减未用药组。

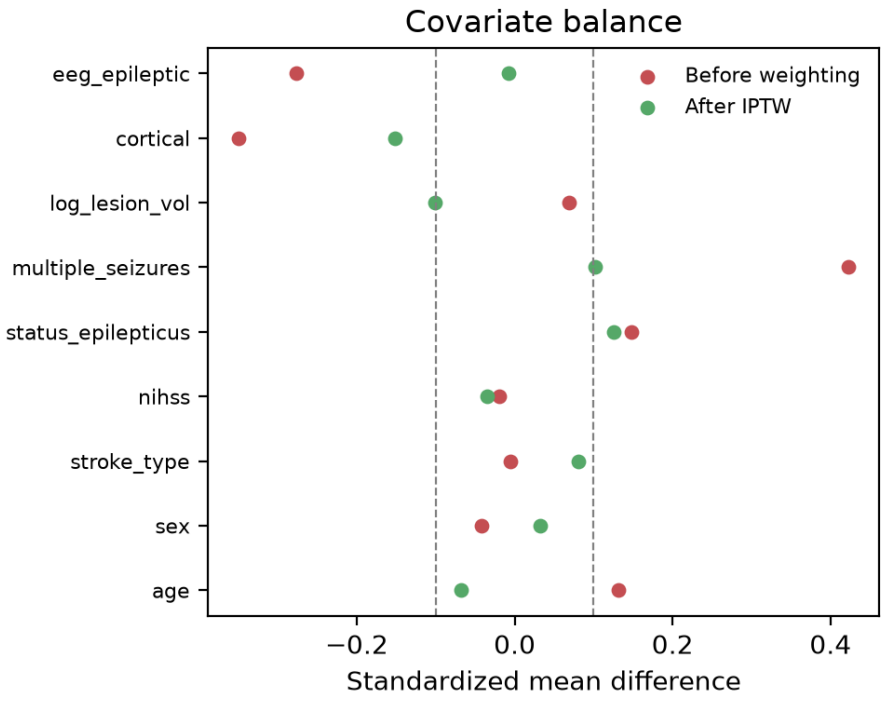


图 9-1　协变量平衡的 Love 图（加权前后）

加权前最大 |SMD| 为 0.423（早期多次发作），加权后降到 0.152（皮层受累）；多数协变量已平衡，但仍有两个超过 0.1。更重要的是倾向评分本身的 c 统计量只有 0.510——它几乎不能区分治疗组与对照组，说明可观测变量无法解释用药选择。因此 IPTW 结果只能作为稳定性检查，不能当作因果估计；真正决定用药的是未测量的发作严重度。

9.3 生存分析

表 9-3 两年无 PSE 生存与限制平均生存时间

指标	ASM（n = 134）	无 ASM（n = 33）	差异 / 检验
两年无 PSE 生存率	0.703	0.745	log-rank p = 0.447
730 天 RMST（天）	561.3	585.0	差 -23.6（-122.4, +81.1）
90 天界标 OR	—	—	0.924（0.320, 3.910）

源文件：results/E/summary_E.json 的 survival。RMST = 限制平均生存时间（0–730 天）。

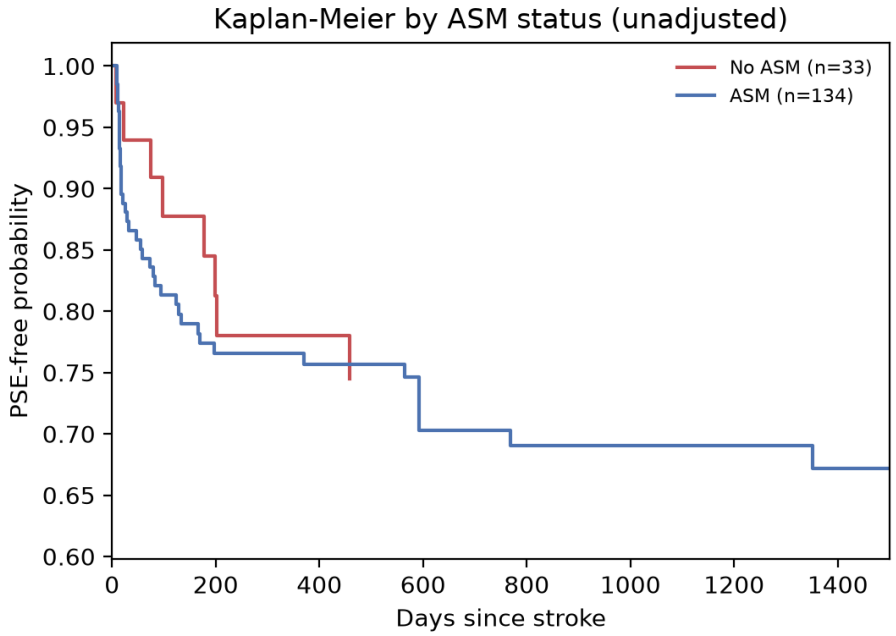


图 9-2 按 ASM 状态的 Kaplan–Meier 两年无 PSE 生存曲线

两条曲线几乎重合：两年无 PSE 生存 70.3% vs 74.5%，log-rank p = 0.447；RMST 差 −23.6 天（95% CI −122.4 至 +81.1）。90 天界标分析（排除最早期的死亡/事件竞争）OR 0.924（0.320–3.910），同样没有信号。比例风险假设未通过检验，因此不报告单一 Cox 风险比——这也是方法节明确写下的决定。

9.4 事件分期与卒中类型分层

表 9-4 按时期划分的 PSE 事件数

时期	ASM 组事件	无 ASM 组事件
0-90 天	24	3
91-365 天	7	4
>365 天	10	1

源文件：results/E/summary_E.json 的 survival.events_by_epoch。

早期事件高度集中在 ASM 组（0–90 天 24 vs 3），随后两组差距收窄（91–365 天 7 vs 4；>365 天 10 vs 1）。这符合指征混杂的预期：临床医生给最严重的患者用药，而最严重的患者最早发生事件；若把 0–90 天的事件当作“药物危害”，就会误读。90 天界标分析正是为此设计，结果无差异。

表 9-5 按卒中类型的 ASM 效应

卒中类型	n（ASM/无）	ASM 组事件率	无 ASM 组事件率	OR（95% CI）
出血性卒中	56（45/11）	28.9%	45.5%	0.487（0.110, 2.140）
缺血性卒中	111（89/22）	31.5%	13.6%	2.907（0.948, 12.131）

源文件：results/E/summary_E.json 的 stroke_type_strata。

分层结果方向相反：出血性卒中 OR 0.488（0.110–2.140），缺血性卒中 OR 2.907（0.948–12.131）。两个区间都很宽，且样本量小（分别为 56 与 111 例），不足以支持“效应异质性”的结论；它更可能反映随机波动与小样本不稳定性。E 研究的立场是描述而非推断：在这 167 例里，没有可复现的保护信号。

10　图表总索引

按编号列出本书全部图与表，以及它们在五套算法架构中的对应位置。算法架构中的编号与本书不完全相同：本书是“结果账本”，编号按数据流排列；算法架构按叙事排列。对应关系以本表为准。

表 10-1　图索引

本书编号	内容	算法架构位置	源文件
图 4-1 / 4-2 / 4-3	A/B/C 校准曲线（n = 8,000）	A/B/C 图 4	fig_calib_{A,B,C}.png
图 4-4 / 4-5 / 4-6	A/B/C 决策曲线（n = 8,000）	A/B/C 图 6	fig_dca_{A,B,C}.png
图 5-1 / 5-2 / 5-3	A/B/C ROC 与 PR 曲线（全队列）	A/B/C 图 2	fig_roc_pr_{A,B,C}.png
图 5-4 / 5-5 / 5-6	A/B/C ROC 与 PR 曲线（去重）	A/B/C 图 7	fig_roc_pr_*_dedup.png
图 6-1 / 6-2 / 6-3	A/B/C 特征重要性	A/B/C 图 5（C 为图 6）	fig_importance_{A,B,C}.png
图 8-1	LR 风险三分位 KM 曲线	D 图 3a	fig_km_lr.png
图 8-2	TabPFN 风险三分位 KM 曲线	D 图 3b	fig_km_tabpfn.png
图 8-3	D 学习曲线	D 图 2	fig_learning_curve.png
图 8-4	D 决策曲线	D 图 4	fig_dca.png
图 9-1	协变量平衡 Love 图	E 补充图	fig_love.png
图 9-2	ASM 分层 KM 曲线	E 图 2	fig_km_asm.png

A/B/C 的学习曲线（图 3-4 至 3-6）由 results/figs/fig_learning_{A,B,C}.png 提供，对应算法架构图 3。

表 10-2　表索引

本书编号	内容	算法架构位置
表 0-1	术语表	—
表 1-1	两套数据划分	方法节
表 1-2	三套特征集	方法节
表 1-3	模型配置	方法节
表 1-4	拟合次数	—
表 2-1 至 2-6	A/B/C × full/dedup 全规模明细	补充材料
表 3-1	n = 8,000 主结果与 CI	A/B/C 表 2
表 3-2	全训练集锚点	A/B/C 表 2 注
表 3-3	计算成本	—
表 4-1 / 4-2	校准斜率与截距	A/B/C 正文
表 5-1	特征块增量	B/C 表 2
表 5-2	模型配对差	A/B/C 正文
表 5-3	数据效率	A/B/C 正文
表 6-1 至 6-3	A/B/C 前十重要性	A 表 3；B/C 表 3
表 7-1	A 的五折 CV 与 OOF	A 表 4
表 8-1	温州队列基线	D 表 1
表 8-2	D 交叉验证	D 表 2
表 8-3	D 配对差	D 正文
表 8-4	ASM 增量	D 正文
表 8-5	KM 三分位	D 正文
表 9-1	E 效应估计	E 表 1
表 9-2	SMD 平衡	E 补充表
表 9-3	生存指标	E 正文
表 9-4	事件分期	E 正文
表 9-5	卒中类型分层	E 正文
表 11-1	文件指纹	—
表 11-2	关键数字锚点	—

11 复现锚点

这一节是给“下一位接手的人”的：不需要读完整本书，只要重跑后比对下面三张表，就能判断环境与数据是否一致。

11.1 文件指纹（SHA-256）

表 11-1 输入文件的 SHA-256

文件	说明	SHA-256
data.csv	公共队列 21,459 行	be84a00921702c45e5c9d250176602b2c62ed96ac41716dca8893b0c5be49d4b
Wenzhou_167_cases_deidentified.csv	温州队列 167 行	98d04a5eb44813e223f9150913637ccc9368d20e1adff80edb11a6bd1af900d4
tabpfn-v2-classifier-finetuned-zk73skhh.ckpt	TabPFN v2 检查点	cf8c519c01eaf1613ee91239006d57b1c806ff5f23ac1aeb1315ba1015210e49

源文件：docs/配置要求与复现说明.md 第 6 节：数据指纹与 split_info.json 的 data_sha256 一致。

哈希值用 `sha256sum` 或 Python `hashlib.sha256` 计算；任何一位不同都说明文件被改动过，后续数字不可直接比较。

11.2 关键数字锚点

表 11-2 重跑后应逐位一致的数字（保留四位小数）

指标	期望值	源文件
A full, n = 8,000: LR AUROC	0.8553	metrics_full_A_final.csv
A full, n = 8,000: LGBM AUROC	0.9378	同上
A full, n = 8,000: TabPFN AUROC	0.9445	同上
B full, n = 8,000: TabPFN AUROC	0.9980	metrics_full_B_final.csv
C full, n = 8,000: TabPFN AUROC	0.9982	metrics_full_C_final.csv
C dedup, n = 8,000: TabPFN AUROC	0.9988	metrics_dedup_C_final.csv
A→B ΔAUROC（LR，full）	+0.1072	table_numbers.json
B→C ΔAUROC（TabPFN，full）	+0.0002	table_numbers.json
D 核心集 LR AUROC（均值）	0.7101	summary_D.json
D 核心集 TabPFN AUROC（均值）	0.6706	summary_D.json
E 粗 OR	1.3777	E/summary_E.json

这些值对环境和数据版本敏感：建议先跑四个规模（100 / 8,000 / 全量）再全量重跑。

11.3 运行顺序

· ① 校验三个输入文件的 SHA-256（表 11-1）。

· ② 运行 A/B/C 基准：固定划分 → 逐规模训练 → 固定测试集评估 → 输出 metrics_*_final.csv 与 preds_*_final.csv。

· ③ 运行汇总与出图：bench_analysis.py → table_numbers.json；restore_analyses.py → restore.json；bootstrap_ci.py → ci.json；make_figures_restore.py → 图。

· ④ 运行 D/E：wenzhou_de.py → summary_D.json 与 E/summary_E.json；table1_wenzhou.py → 基线表。

· ⑤ 比对表 11-2；全部一致后再重新生成本书与五套算法架构的 docx/PDF。

环境提示：LR 支路需要 scikit-learn 1.7.2 的旧环境才能与归档锚点逐位一致；LGBM/TabPFN 与 D/E 在 scikit-learn 1.9.1、pandas 3.0.6、numpy 2.5.3、lightgbm 4.7.0、tabpfn 9.2.0 的新环境运行。本机用 `py -3.12`。两套环境的完整版本表与逐条命令见《配置要求与复现说明》第 2–6 节。

11.4 版本说明

本书对应第五次大跑数的最终归档。与之前几次相比，本次的关键变化是：TabPFN 补跑到 8,000 例上限、新增去重臂、并把温州 167 例的 D/E 研究纳入同一结果体系。早期版本的 A/B/C 曾使用不同的图表组合（例如缺少基线表、ROC/PR 或特征重要性）；本次已把两版内容合并，算法架构与本书使用同一套数字。如发现本书与旧版 PDF 不一致，以本书为准。